

# Formelsammlung

July 12, 2018

# Contents

<b>1</b>	<b>Bayes'scher Ansatz</b>	<b>3</b>
1.1	Entscheidungsregionen . . . . .	3
1.1.1	Ungleiche Klassifizierungswahrscheinlichkeit . . . . .	3
1.1.2	Fehlklassifizierung . . . . .	3
1.1.3	Umformung . . . . .	3
1.1.4	pq-Formel . . . . .	4
1.2	Zurückweisung . . . . .	4
<b>2</b>	<b>Lineare Klassifikatoren</b>	<b>5</b>
2.1	Fisher Diskriminante . . . . .	6
2.2	Lineare Kleinste Quadrate . . . . .	6
<b>3</b>	<b>Perceptron</b>	<b>6</b>
3.1	Bestimmung der Diskriminanzfunktion . . . . .	7
3.1.1	Bestimmung der nächsten Diskriminanzfunktion . . . . .	7
<b>4</b>	<b>Hough-Transformation</b>	<b>7</b>
<b>5</b>	<b>Abstandsmaße</b>	<b>7</b>
5.1	Pearson . . . . .	7
<b>6</b>	<b>Linkage Algorithmen</b>	<b>8</b>
6.1	Single Linkage . . . . .	8
6.2	Complete linkage . . . . .	8

# 1 Bayes'scher Ansatz

## 1.1 Entscheidungsregionen

Bei gleicher Klassifizierungswahrscheinlichkeit gilt

$$p(x|C_1) = p(x|C_2)$$

$$p(x|C_i) = \frac{1}{\sqrt{2\pi\sigma_i^2}} \cdot e^{-\frac{1}{2} \frac{(x-\mu_i)^2}{\sigma_i^2}}$$

### 1.1.1 Ungleiche Klassifizierungswahrscheinlichkeit

Wenn eine Klasse wahrscheinlicher ist so gilt

$$p(C_1) \cdot p(x|C_1) = p(x|C_2) \cdot p(C_2)$$

$$\frac{p(C_1)}{p(C_2)} \cdot \frac{\sqrt{2\pi\sigma_2^2}}{\sqrt{2\pi\sigma_1^2}} = e^{-\frac{1}{2} \frac{(x-\mu_2)^2}{\sigma_2^2} - \frac{1}{2} \frac{(x-\mu_1)^2}{\sigma_1^2}}$$

$\frac{p(C_1)}{p(C_2)}$  definieren wir als  $\mathcal{P}$ . Als Reziproke von  $\mathcal{P}$  bezeichnen wir  $\mathcal{P}'$ . Bei gleichen Wahrscheinlichkeiten  $p(C_{1/2}) = 0,5$  ist  $\mathcal{P} = 1$  und kann ignoriert werden.

### 1.1.2 Fehlklassifizierung

Wenn eine Verlustmatrix  $V$  gegeben ist so wird die Gewichtung der Fehlklassifikation pro Klasse berücksichtigt über

$$V_{1,2} \cdot p(x|C_1) = p(x|C_2) \cdot V_{2,1}$$

$$\frac{V_{1,2}}{V_{2,1}} \cdot \frac{\sqrt{2\pi\sigma_2^2}}{\sqrt{2\pi\sigma_1^2}} = e^{-\frac{1}{2} \frac{(x-\mu_2)^2}{\sigma_2^2} - \frac{1}{2} \frac{(x-\mu_1)^2}{\sigma_1^2}}$$

$\frac{V_{1,2}}{V_{2,1}}$  definieren wir als  $\mathcal{V}$ . Bei gleicher Verlustgewichtung  $V_{(1/2),(2/1)} = x$  ist  $\mathcal{V} = 1$  und kann ignoriert werden.

### 1.1.3 Umformung

Mit diesen Parametern kann die Formel wie folgt umgeformt werden

$$\ln(\mathcal{P} \cdot \mathcal{V} \cdot \frac{\sqrt{\sigma_2^2}}{\sqrt{\sigma_1^2}}) = \frac{-\frac{1}{2}(x-\mu_2)^2}{\sigma_2^2} - \frac{-\frac{1}{2}(x-\mu_1)^2}{\sigma_1^2} \quad (1)$$

$$\sigma_2^2 \cdot \sigma_1^2 \cdot \ln(\mathcal{P} \cdot \mathcal{V} \cdot \frac{\sqrt{\sigma_2^2}}{\sqrt{\sigma_1^2}}) = -\frac{1}{2} \cdot \sigma_1^2 (x - \mu_2)^2 - \frac{1}{2} \cdot \sigma_2^2 (x - \mu_1)^2 \quad (2)$$

$$\begin{aligned} -2 \cdot \sigma_2^2 \cdot \sigma_1^2 \cdot \ln(\mathcal{P} \cdot \mathcal{V} \cdot \frac{\sqrt{\sigma_2^2}}{\sqrt{\sigma_1^2}}) &= \sigma_1^2 (x^2 - 2\mu_2 x + \mu_2^2) - \sigma_2^2 (x^2 - 2\mu_1 x + \mu_1^2) \quad (3) \\ &= (\sigma_1^2 - \sigma_2^2) \cdot x^2 + 2(-\mu_2 \sigma_1^2 + \mu_1 \sigma_2^2) x + \sigma_1^2 \mu_2^2 - \sigma_2^2 \mu_1^2 \quad (4) \end{aligned}$$

$$0 = (\sigma_1^2 - \sigma_2^2) \cdot x^2 + 2(-\mu_2 \sigma_1^2 + \mu_1 \sigma_2^2) x + \sigma_1^2 \mu_2^2 - \sigma_2^2 \mu_1^2 + 2 \cdot \sigma_2^2 \cdot \sigma_1^2 \cdot \ln(\mathcal{P} \cdot \mathcal{V} \cdot \frac{\sqrt{\sigma_2^2}}{\sqrt{\sigma_1^2}}) \quad (5)$$

#### 1.1.4 pq-Formel

Benötigt einen Ausdruck der Form  $x^2 + px + q = 0$ . Um die pq-Formel  $x_{1/2} = -\frac{p}{2} \pm \sqrt{(\frac{p}{2})^2 - q}$  anzuwenden muss der Term mit  $/ \div (\sigma_1^2 - \sigma_2^2)$  umgeformt werden

#### 1.2 Zurückweisung

$$p(C_1|x) \geq \theta$$

$$p(C_1|x) = \frac{p(C_1) \cdot p(x|C_1)}{p(x)}$$

$$p(x) = p(C_1) \cdot p(x|C_1) + p(C_2) \cdot p(x|C_2)$$

$$\frac{p(C_1) \cdot p(x|C_1)}{p(C_1) \cdot p(x|C_1) + p(C_2) \cdot p(x|C_2)} \geq \theta$$

Dieser Ausdruck hat die Form  $\frac{A}{A+B}$  was umgeformt werden kann in  $\frac{1}{1+\frac{B}{A}}$

$$\frac{1}{1 + \frac{p(C_2) \cdot p(x|C_2)}{p(C_1) \cdot p(x|C_1)}} \geq \theta$$

$$1 \geq \theta \left(1 + \frac{p(C_2) \cdot (x|C_2)}{p(C_1) \cdot p(x|C_1)}\right) \quad (6)$$

$$\frac{1}{\theta} \geq 1 + \mathcal{P}' \cdot \frac{p(x|C_2)}{p(x|C_1)} \quad (7)$$

$$\frac{1}{\theta} - 1 \geq \mathcal{P}' \cdot \frac{\frac{1}{\sqrt{2\pi\sigma_2^2}} \cdot e^{-\frac{1}{2}\frac{(x-\mu_2)^2}{\sigma_2^2}}}{\frac{1}{\sqrt{2\pi\sigma_1^2}} \cdot e^{-\frac{1}{2}\frac{(x-\mu_1)^2}{\sigma_1^2}}} \quad (8)$$

$$\frac{1}{\theta} - 1 \geq \mathcal{P}' \cdot \frac{\sqrt{2\pi\sigma_1^2}}{\sqrt{2\pi\sigma_2^2}} \cdot e^{-\frac{1}{2}\frac{(x-\mu_2)^2}{\sigma_2^2} - \frac{1}{2}\frac{(x-\mu_1)^2}{\sigma_1^2}} \quad (9)$$

Nun kann analog zu 1 der Term weiter umgeformt werden zu

$$0 = (\sigma_1^2 - \sigma_2^2) \cdot x^2 + (-\mu_2\sigma_1^2 + \mu_1\sigma_2^2)2x + \sigma_1^2\mu_2^2 - \sigma_2^2\mu_1^2 + 2 \cdot \sigma_1^2 \cdot \sigma_2^2 \cdot \ln\left(\left(\frac{1}{\theta} - 1\right) \cdot \mathcal{P}' \cdot \frac{\sqrt{\sigma_2^2}}{\sqrt{\sigma_1^2}}\right)$$

Nun muss für  $p(C_2|x)$  dies Analog geschehen

$$\frac{p(C_2) \cdot p(x|C_2)}{p(C_1) \cdot p(x|C_1) + p(C_2) \cdot (x|C_2)} \geq \theta$$

$$\frac{1}{1 + \frac{p(C_1) \cdot p(x|C_1)}{p(C_2) \cdot p(x|C_2)}} \geq \theta$$

$$\frac{1}{\theta} \geq 1 + \mathcal{P} \cdot \frac{p(x|C_1)}{p(x|C_2)}$$

$$\frac{1}{\theta} - 1 \geq \mathcal{P} \cdot \frac{\sqrt{2\pi\sigma_2^2}}{\sqrt{2\pi\sigma_1^2}} \cdot e^{-\frac{1}{2}\frac{(x-\mu_1)^2}{\sigma_1^2} - \frac{1}{2}\frac{(x-\mu_2)^2}{\sigma_2^2}}$$

$$0 = (\sigma_2^2 - \sigma_1^2) \cdot x^2 + (-\mu_1\sigma_2^2 + \mu_2\sigma_1^2)2x + \sigma_2^2\mu_1^2 - \sigma_1^2\mu_2^2 + 2 \cdot \sigma_1^2 \cdot \sigma_2^2 \cdot \ln\left(\left(\frac{1}{\theta} - 1\right) \cdot \mathcal{P} \cdot \frac{\sqrt{\sigma_1^2}}{\sqrt{\sigma_2^2}}\right)$$

## 2 Lineare Klassifikatoren

Klassifizieren eines Vektors  $V$  wird durch Wenn  $V = \begin{pmatrix} x_1 \\ x_2 \end{pmatrix}$  so kann die Gleichung gegen null gesetzt werden und dieses Ergebniss ist die Diskriminanzfunktion.

$$w^{*T} \cdot V + w_0 \quad (10)$$

Das Signum des Ergebnisses gibt die Klassifizierung an.

## 2.1 Fisher Diskriminante

Berechnen des Klassenmittelpunktes  $\mu$  der Klasse  $i$

$$\mu_i = \frac{1}{|i|} \left( \sum_{k \in C_i} x_k \right)$$

Berechnen der Kovarianz zwischen den Klassen

$$S_B = (\mu_2 - \mu_1)(\mu_2 - \mu_1)^T$$

Berechnen der Gesamtkovarianz innerhalb der Klassen

$$S_W = \sum_{k \in C_1} (x_k - \mu_1)(x_k - \mu_1)^T + \sum_{k \in C_2} (x_k - \mu_2)(x_k - \mu_2)^T$$

$$w^* = S_W^{-1}(\mu_2 - \mu_1)$$

$$w_0^* = -w^{*T} \frac{1}{N} (N_1 \mu_1 + N_2 \mu_2)$$

wobei  $N$  die Anzahl aller Klassifizierten Vektoren und  $N_i$  die Anzahl der Vektoren die in der Klasse  $i$  ist

Über 10 kann nun die Diskriminanzfunktion bestimmt oder Punkte Klassifiziert werden.

## 2.2 Lineare Kleinste Quadrate

Erweitern von  $w$  in höhere Dimension

Berechnung der Diskriminanzfunktion  $w^*$

$$w^* = (X X^T)^{-1} X t^T$$

Über 10 kann nun die Diskriminanzfunktion bestimmt oder Punkte Klassifiziert werden.

## 3 Perceptron

Überführung des Inputs in höher Dimensionales Problem  $x \in R^{D+1}$

$$x = \begin{pmatrix} 1 & 1 & 1 & 1 & \dots \\ x_1 & x_2 & x_3 & x_4 & \dots \\ y_1 & y_2 & y_3 & y_4 & \dots \\ \vdots & & & & \end{pmatrix}$$

### 3.1 Bestimmung der Diskriminanzfunktion

zum Zeitpunkt  $t$

$$\begin{aligned} g &= w^T x + w_0 \cdot 1 \\ &= (w_1 \quad w_2) \cdot \begin{pmatrix} x_1 \\ x_2 \end{pmatrix} + w_0 \cdot 1 \\ &= (w_0 \quad w_1 \quad w_2) \cdot \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix} \\ 0 &= w(t)^T * \begin{pmatrix} 1 \\ x_1 \\ x_2 \end{pmatrix} \end{aligned} \tag{11}$$

Durch einsetzen kann auch die Klassifikation eines Punktes bestimmt werden.

#### 3.1.1 Bestimmung der nächsten Diskriminanzfunktion

$$\begin{aligned} w(t+1) &= w(t) - \rho(t) \frac{\partial}{\partial w} J(w)|_{w=w(t)} \\ \frac{\partial}{\partial w} J(w)|_{w=w(t)} &= \sum_{k \in Y} -t_k \cdot x_k \end{aligned}$$

wobei  $Y$  die Menge aller falsch klassifizierten Punkte beschreibt.

## 4 Hough-Transformation

$r(\rho) = \cos(\rho) \cdot x_1 + \sin(\rho) \cdot x_2$  wobei  $\rho$  die Abtaste ist.

## 5 Abstandsmaße

$d_1$  = manhattan Abstand. Definiert durch  $d_1 = |(x_1 - x_2)| + |(y_1 - y_2)|$   
 $d_2$  = euklidischer Abstand. Definiert durch  $d_2 = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2}$   
 $d_p(x, y) = (\sum_{i=1}^l w_i \cdot |x_i - y_i|^p)^{1/p}$

### 5.1 Pearson

Wenn der Vektor  $x$  aus  $i$  Werten besteht so ist

$$\begin{aligned} \bar{x} &= \frac{1}{|x|} \sum x_i \\ x_d &= x - \bar{x} * \mathbf{1} \\ d_{Pearson}(x, y) &= \frac{x_d^T y_d}{||x_d|| \cdot ||y_d||} \\ ||x|| &= \sqrt{\sum x_i^2} \end{aligned}$$

## **6 Linkage Algorithmen**

### **6.1 Single Linkage**

minimaler Abstand zwischen den Punkten

### **6.2 Complete linkage**

maximaler Abstand zwischen den Punkten